NLP 第二次编程作业

强基数学 002
吴天阳 2204210460，马煜璇 2204220461

1 实验目的

使用文本数据集，网址：http://www.cs.cmu.edu/afs/cs/project/theo-11/www/naive-bayes.html

该数据集中包含两个文本数据集：

1. 总数据集 `20_newsgroups`：包含 20 种不同的新闻类别，总计共有 19997 篇文档，每种类别下应该平均有 1000 份新闻文档.
2. 子类文档 `mini_newsgroups`：由第一个总数据集中每种类别的新闻中随机选择 100 份，总计 2000 份文档，用于验证算法的准确度.

我们将使用第一个数据集作为训练集，用第二个数据集作为验证集，用于判断模型的准确率. 选取的分类模型包括 K 近邻和前馈神经网络.

2 实验原理

2.1 K 近邻

首先构建词向量空间 X，将训练集文本均转化为词向量后得到词向量空间中的子集 G，对于验证集中的每一个文本也转化为词向量 $\boldsymbol{x}$，通过选取 X 中距离 $\boldsymbol{x}$ 前 K 个距离最小的元素，选取这 K 个中出现次数最高的种类作为预测结果.

由于 K 近邻算法需要选择较好的 K 值，若 K 大小过小，可能发生过拟合现象，K 大小过大，可能预测效果不好. 所以我们通过多次计算不同的 K 值，选取结果中平均预测率最高 K 值.

2.2 前馈神经网络

先将测试集和验证集的文本全部转化为词向量，注意由于验证集是测试集的子集，需要在测试集中将验证集相同的数据删去.

假设词向量维数为 N，则前馈神经网络的输入层有 N 个神经元，隐藏层设定为 1 层，神经元个数设置为 32，由于一共有 20 中类别，所以将输出层神经元个数设置为 20.

隐藏层的激活函数设置为 $sigmoid(x)=\dfrac{1}{1+\mathrm{e}^{-x}}$，输出层使用 $softmax$ 函数将输出转化为概率 $softmax(z_i)=\dfrac{\mathrm{e}^{z_i}}{\sum_{j=1}^{20} z_j}$，最后损失函数选择交叉熵损失函数

$$L(y,\hat{y})=-\sum_{i=1}^{20} y_i \log \hat{y}_i=-y_c \log \hat{y}_c$$

如果当前类别属于第 c 类，则标签对应 one-hot 向量为 $y_i = (\underbrace{0, \cdots, 0, 1}_{c个}, 0, \cdots, 0)$，所以才能将损失函数写为后者的形式.

2.3 实验环境

```
Python      '3.9.12'
numpy       '1.20.0'
matplotlib  '3.5.1'
nltk        '3.7'
tensorflow  '2.6.0'
```

编辑器使用的是 Jupyter notebook. 全部代码已上传至GitHub.

3 实验步骤与结果分析

3.1 数据预处理

3.1.1 文件读入处理

将 20 种文件类型进行编号，并查看内部的文档数目，使用 Python3.6 以上的路径处理包 pathlib 中 Path 类，对文件路径进行处理：

```python
def initDataset(fname, showInfo=True):
    path = Path(fname)  # 将路径转化为 Path 类
    folds = [f.name for f in path.iterdir() if f.is_dir()]  # 获取文件夹名称
    for id, fold in enumerate(folds):  # 一共有 20 个文件夹，分别对其内部文件进行处理
        print(f'处理第{id+1}/{len(folds)}个文件夹{fold}中...')
        now = path.joinpath(fold)
        files = [f.name for f in now.iterdir() if f.is_file()]  # 获取当前文件夹内的文件名
        for file in tqdm(files):  # 获取文件文件名
            pathFile = now.joinpath(file)
            with open(pathFile, errors='replace') as f:  # 打开文件进行处理
            #... 文档处理
```

通过观察文档内容，可以发现，文档主要是由两部分构成，第一部分为文档的相关信息，而正文与相关信息之间由一个换行符分开，所以我们通过判断第一个换行符，来提取正文部分.

文本格式如下：

```
Xref: ...
Newsgroups: ...
Path: ...
From: ...
Subject: ...
Message-ID: ...
Organization: ...
References: ...
Lines: ...

In article <C51C4r.BtG@csc.ti.com> rowlands@hc.ti.com (Jon Rowlands)
    writes:
... 以下都是正文
```

文本文件预处理代码：

```
with open(pathFile, errors='replace') as f:  # 打开文件进行处理
    s = f.readline()
    while s != "\n":  # 先找到第一个换行符，下面则是正文
        s = f.readline()
        text = f.read()
```

3.1.2 分词操作

首先将 20 类的文档全部读入，将数据的主要成分提取出来，然后利用 NLTK 库的分词功能

1. 将文章转化为小写 words.lower()
2. 划分 nltk.word_tokenize(words)
3. 标点符号去除，用正则表达式判断单词中是否包含英文，若不包含则删去
4. 去除停用词，利用 nltk.corpus.stopwords('english') 获得停用词词库
5. 词干提取，使用 nltk.stem.porter.PorterStemmer(word) 词干提取方法
6. 词性还原，使用 nltk.stem.WordNetLemmatizer(word) 还原词性

```
def extractWords(words):  # 提取分词
    words = words.lower()
    words = word_tokenize(words)  # 分词
    dropWords = ["n't"]  # 这个是计算结果中出现次数第一的，但明显不重要
    words = [word for word in words if re.match(r'[A-Za-z]', word) and word
    not in dropWords]  # 保证单词中必须包含字母
    stops = set(stopwords.words('english'))
    words = [word for word in words if word not in stops]
```

```
    tmp = []  # 词干提取 + 还原词性
    for word in words:
        stem = PorterStemmer().stem(word)  # 词干提取
        pos = ['n', 'v', 'a', 'r', 's']  # 名词，动词，形容词，副词，附属形容词
        for p in pos:
            stem = WordNetLemmatizer().lemmatize(stem, pos=p)
        tmp.append(stem)  # 还原词性，附属形容词
    words = tmp
    return words
```

数据集 20_newsgroups 提取出的全部数据的相关信息，分别为：类别，编号，文件数，分词数目，词频出现次数最高的前 5 个词.

```
          Class  Id Files  Words  Most common words
    alt.atheism:  0  1000  10950  ['write', 'say', 'one', 'god', 'would']
  comp.graphics:  1  1000  13406  ['imag', 'file', 'use', 'program', 'write']
ms-windows.misc:  2  1000  48850  ['max', 'g', 'r', 'q', 'p']
ibm.pc.hardware:  3  1000  10353  ['drive', 'use', 'get', 'card', 'scsi']
sys.mac.hardware:  4  1000   9354  ['use', 'mac', 'get', 'write', 'appl']
  comp.windows.x:  5  1000  20392  ['x', 'use', 'window', 'file', 'program']
    misc.forsale:  6  1000  10830  ['new', 'sale', 'offer', 'use', 'sell']
       rec.autos:  7  1000  10378  ['car', 'write', 'get', 'articl', 'would']
 rec.motorcycles:  8  1000  10207  ['write', 'bike', 'get', 'articl', 'dod']
  sport.baseball:  9  1000   9164  ['game', 'year', 'write', 'good', 'get']
rec.sport.hockey: 10  1000  11311  ['game', 'team', 'play', 'go', 'get']
       sci.crypt: 11  1000  13087  ['key', 'use', 'encrypt', 'would', 'write']
 sci.electronics: 12  1000  10480  ['use', 'one', 'would', 'write', 'get']
         sci.med: 13  1000  15271  ['use', 'one', 'write', 'get', 'articl']
       sci.space: 14  1000  13867  ['space', 'would', 'write', 'orbit', 'one']
       christian: 15   997  12616  ['god', 'christian', 'one', 'would', 'say']
   politics.guns: 16  1000  14626  ['gun', 'would', 'write', 'peopl', 'articl']
politics.mideast: 17  1000  15105  ['armenian', 'say', 'peopl', 'one', 'write']
   politics.misc: 18  1000  13727  ['would', 'write', 'peopl', 'say', 'articl']
   religion.misc: 19  1000  12390  ['write', 'say', 'one', 'god', 'would']
                 19997 146437  ['write', 'would', 'one', 'use', 'get']
```

3.2 分类模型

3.2.1 K 近邻

选择前 1000 个出现频率最高的单词作为词向量的基，这里列出部分词作为基：

```
write, would, one, use, get, articl, say, know, like, think, make, peopl,
↪ good, go, time, x, see, also, could, work, u, take, right, new, want,
↪ system, even, way, year, thing, come, well, find, may, give, look,
↪ need, god, problem, much, mani, tri, first, two, file, mean, max,
↪ believ, call, run, question, point, q, anyon, post, seem, program,
↪ state, window, tell, differ, r, drive, read, realli, someth, plea,
↪ includ, g, sinc, thank...
```

将文档转化为词向量，单位化到 100，由于总共有 1000 维，如果单位化为 1，每一位大小过小，产生精度问题.

```
def word2vector(word):  # 通过文档生成词向量
    x = np.ones(N)  # 初始化全为 1，正则化向量，保证没有 0 分量
    for t in w:
        if t in word2num:
            x[word2num[t]] += 1
    x /= x.sum() / 100
    return x
```

```
# KNN 算法
def KNN(word, K=[4]):  # word 为原始文档，K 可以是一个 list，包含多个 K 值，返
↪ 回不同 K 值的预测结果
    now = word2vector(word)  # 获得当前文档的词向量
    dist = []
    for x, y in data:
        dist.append((np.linalg.norm(now - x), y))  # 计算欧氏距离
    dist = sorted(dist, key=(lambda x: x[0]))  # 递增排序
    ret = []
    for k in K:
        tmp = dist[1:k+1]  # 获得前 k 个，由于原数据集包含当前数据，第 0 个必然
        ↪ 是自身，所以跳过第 0 个
        classify = [c[1] for c in tmp]
        ret.append(collections.Counter(classify).most_common()[0][0])  # 找
        ↪ 到出现次数最多的类别作为预测值
    return np.array(ret)
```

计算不同的 K 值求解正确率，取平均正确率最高的一组，此处设定了几种 K 的取值：

```
K = [1,2,3,4,5,6,7,8,9,10, 20, 50, 100]
K=1, 正确率: 58.00%
```

```
K=2, 正确率: 58.00%
K=3, 正确率: 56.40%
K=4, 正确率: 55.85%
K=5, 正确率: 54.10%
K=6, 正确率: 52.50%
K=7, 正确率: 51.60%
K=8, 正确率: 50.30%
K=9, 正确率: 48.75%
K=10, 正确率: 48.20%
K=20, 正确率: 42.70%
K=50, 正确率: 37.25%
K=100, 正确率: 33.55%
```

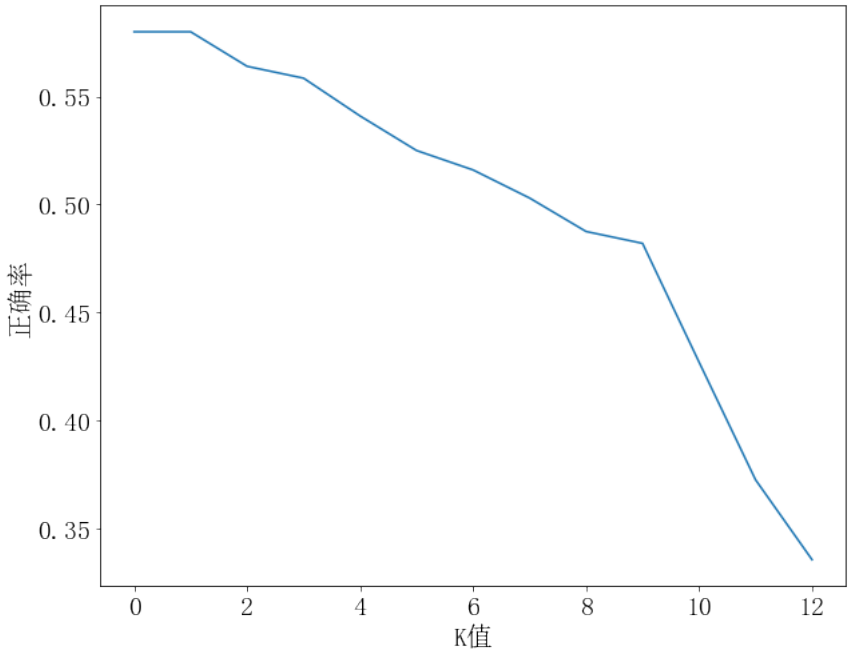

我们发现 K 越小正确率越高，但是 K 过小可能发生过拟合，所以最后选取了 K=4

```
K 为 4 时, 平均正确率较高 55.85%
第  1 组类别, 正确率: 0.43
第  2 组类别, 正确率: 0.55
第  3 组类别, 正确率: 0.51
第  4 组类别, 正确率: 0.38
第  5 组类别, 正确率: 0.56
第  6 组类别, 正确率: 0.44
第  7 组类别, 正确率: 0.42
第  8 组类别, 正确率: 0.46
第  9 组类别, 正确率: 0.67
第 10 组类别, 正确率: 0.57
```

```
第 11 组类别，正确率：0.70
第 12 组类别，正确率：0.62
第 13 组类别，正确率：0.51
第 14 组类别，正确率：0.57
第 15 组类别，正确率：0.57
第 16 组类别，正确率：0.50
第 17 组类别，正确率：0.56
第 18 组类别，正确率：0.72
第 19 组类别，正确率：0.43
第 20 组类别，正确率：0.65
```

3.2.2 前馈型神经网络

使用 TensorFlow 神经网络框架

```
import tensorflow as tf
import tensorflow.keras as keras
import tensorflow.keras.layers as layers
```

构造训练集，并随机打乱，设置 batch 大小为 16，重复原始数据集 5 次，得到包含构造训练集，并随机打乱，设置 batch 大小为 16，重复原始数据集 5 次，得到包含 $17835 \times 5 = 89175$ 个元素的数据集，每次对其进行训练（原始数据集太小了，放大了 5 倍）

```
train_x, train_y = [], []
test_x, test_y = [], []
tmp = [w for words in test_words for w  in words]
for i in range(20):
    for w in test_words[i]:  # 测试集
        x = word2vector(w)
        test_x.append(x)
        test_y.append(i)
    for w in words[i]:  # 训练集
        if w not in tmp:  # 训练集元素不能在测试集中出现
            x = word2vector(w)
            train_x.append(x)
            train_y.append(i)
# 转化为 np.ndarray 的形式
train_x = np.array(train_x)
train_y = np.array(train_y)
test_x = np.array(test_x)
test_y = np.array(test_y)
```

```
# 构建为 tf.data.Dataset 数据类型
train = tf.data.Dataset.from_tensor_slices((train_x, train_y))
train = train.shuffle(10000).batch(16).repeat(5)  # 对数据集进行预处理
test = tf.data.Dataset.from_tensor_slices((test_x, test_y))
```

构建神经网络模型，包含一个含有 32 个神经元的隐藏层，使用 sigmoid 作为激活函数，softmax 函数作为输出层的激活函数，使用交叉熵损失函数.

```
model = keras.Sequential([
    layers.Dense(32, activation='sigmoid', input_shape=[N,]),  # 隐藏层
    layers.Dense(20, activation='softmax')  # 输出层
])
model.compile(optimizer='adam',  # 优化器
              loss = keras.losses.SparseCategoricalCrossentropy(),  # 损失函数
              metrics=['accuracy'])  # 将准确率作为预测指标
history = model.fit(train, epochs=20, validation_data=(test_x, test_y))
```

训练 20 次，得到的损失和准确率如图下图所示，15 次以后，验证集准确率基本稳定在 70%，训练集准确率稳定在 80% 左右. 下图准确率最终稳定在 70.9%

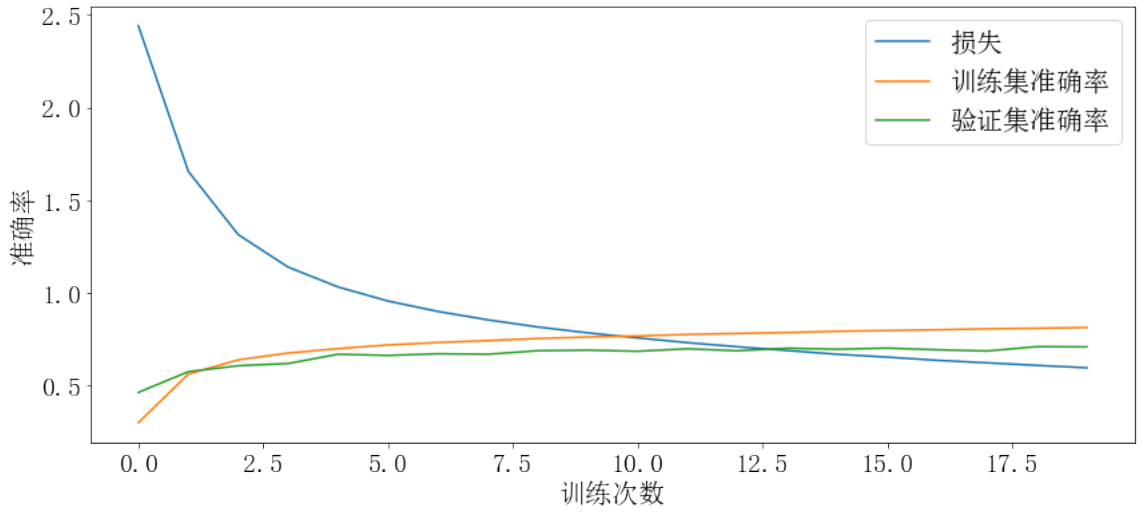

4 结论与讨论

通过本次实验，学会了使用 nltp 包对文档进行分词操作，对原式文档进行预处理，使用 KNN 和前馈神经网络两种不同的模型对文档进行分类预测，正确率分别在 55.85% 和 70.9% 左右，效果均不是非常好，仍有待改进.

A 附录

A.1 神经网络训练日志

```
Epoch 1/20
5575/5575 [==============================] - 18s 3ms/step - loss: 2.4416 - accuracy: 0.3004 - val_loss: 2.0228 - val_accuracy: 0.4635
Epoch 2/20
5575/5575 [==============================] - 19s 3ms/step - loss: 1.6565 - accuracy: 0.5624 - val_loss: 1.5213 - val_accuracy: 0.5755
Epoch 3/20
5575/5575 [==============================] - 17s 3ms/step - loss: 1.3149 - accuracy: 0.6392 - val_loss: 1.3432 - val_accuracy: 0.6075
Epoch 4/20
5575/5575 [==============================] - 19s 3ms/step - loss: 1.1396 - accuracy: 0.6762 - val_loss: 1.2247 - val_accuracy: 0.6195
Epoch 5/20
5575/5575 [==============================] - 16s 3ms/step - loss: 1.0325 - accuracy: 0.6998 - val_loss: 1.1397 - val_accuracy: 0.6695
Epoch 6/20
5575/5575 [==============================] - 16s 3ms/step - loss: 0.9565 - accuracy: 0.7197 - val_loss: 1.0940 - val_accuracy: 0.6630
Epoch 7/20
5575/5575 [==============================] - 16s 3ms/step - loss: 0.9004 - accuracy: 0.7326 - val_loss: 1.0728 - val_accuracy: 0.6720
Epoch 8/20
5575/5575 [==============================] - 21s 4ms/step - loss: 0.8550 - accuracy: 0.7433 - val_loss: 1.0415 - val_accuracy: 0.6695
Epoch 9/20
5575/5575 [==============================] - 21s 4ms/step - loss: 0.8165 - accuracy: 0.7541 - val_loss: 1.0145 - val_accuracy: 0.6885
Epoch 10/20
5575/5575 [==============================] - 25s 5ms/step - loss: 0.7849 - accuracy: 0.7625 - val_loss: 1.0055 - val_accuracy: 0.6915
Epoch 11/20
5575/5575 [==============================] - 29s 5ms/step - loss: 0.7575 - accuracy: 0.7680 - val_loss: 1.0040 - val_accuracy: 0.6855
Epoch 12/20
5575/5575 [==============================] - 27s 5ms/step - loss: 0.7320 - accuracy: 0.7765 - val_loss: 0.9934 - val_accuracy: 0.6990
Epoch 13/20
5575/5575 [==============================] - 27s 5ms/step - loss: 0.7100 - accuracy: 0.7818 - val_loss: 1.0070 - val_accuracy: 0.6880
Epoch 14/20
5575/5575 [==============================] - 29s 5ms/step - loss: 0.6894 - accuracy: 0.7867 - val_loss: 0.9691 - val_accuracy: 0.7020
Epoch 15/20
5575/5575 [==============================] - 26s 5ms/step - loss: 0.6694 - accuracy: 0.7934 - val_loss: 0.9863 - val_accuracy: 0.6965
Epoch 16/20
5575/5575 [==============================] - 25s 5ms/step - loss: 0.6540 - accuracy: 0.7975 - val_loss: 0.9796 - val_accuracy: 0.7025
Epoch 17/20
5575/5575 [==============================] - 26s 5ms/step - loss: 0.6368 - accuracy: 0.8013 - val_loss: 0.9810 - val_accuracy: 0.6935
Epoch 18/20
5575/5575 [==============================] - 25s 4ms/step - loss: 0.6231 - accuracy: 0.8067 - val_loss: 1.0227 - val_accuracy: 0.6870
Epoch 19/20
5575/5575 [==============================] - 25s 5ms/step - loss: 0.6094 - accuracy: 0.8097 - val_loss: 0.9688 - val_accuracy: 0.7105
Epoch 20/20
5575/5575 [==============================] - 24s 4ms/step - loss: 0.5964 - accuracy: 0.8138 - val_loss: 0.9776 - val_accuracy: 0.7090
```